

Blok 1: Klasifikacija teksta i BoW

Zadatak 1

Izmeniti funkciju `spacy_preprocessing` tako da iz zadatog teksta (ulazni argument) budu zadržane samo reči koje su imenice, pridevi i glagoli

Kreirati i evaluirati model dobijen sa ovim oblikom selekcije atributa

Zadatak 2

Koristeći spaCy, kreirati nove attribute koji predstavljaju:

- Broj imenica
- Broj glagola
- Broj imenovanih entiteta
- Broj znakova interpunkcije

Ispitati koliko su ovi atributi potencijalno značajni za predviđanje izlazne varijable

Zadatak 3

Istražiti argumente CountVectoriser konstruktora (tj hiperparametre koje je moguće podešavati) i njihov efekat na performanse klasifikatora:

- Utvrditi (npr. pretragom neta) koji su to argumenti CountVectoriser-a koji se najčešće podešavaju i u kojim opsezima se njihove vrednosti tipično traže
- Uvrstiti neki od identifikovanih značajnih argumenata u postupak finog podešavanja (fine-tuning) pipeline-a rađen na času predavanja i ispitati kako se to odražava na performanse klasifikacije