# Primer zadatka klasifikacije teksta

U fajlu “McDonald_s_Reviews.csv”[1] su dati podaci o komentarima korisnika McDonalds restorana o ovim restoranima, hrani, usluzi. Fajl sadrži sledeće kolone (varijable):

- *reviewer_id* - jedinstveni identifikator korisnika koji je ostavio komentar
- *store_address* - adresa restorana na koji se komentar odnosi
- *rating_count* - ukupan broj komentara za dati restoran
- *review* - tekst komentara korisnika
- *rating* - ocena koju je korisnik dao restoranu

Koristeći opisane podatke iz navedenog fajla, potrebno je uraditi sledeće:

- Polazeći od kolone *rating* napraviti novu *sentiment* varijablu sa tri moguće vrednosti (negativan, neutralan, pozitivan) primenjujući sledeće mapiranje:
  - rating 1 i 2 se mapiraju u “negativan” sentiment,
  - rating 3 se mapira u “neutralan” sentiment,
  - rating 4 i 5 se mapiraju u “pozitivan” sentiment

  Varijabla *sentiment* bi trebalo da posluži kao izlazna varijabla za klasifikaciju u ovom zadatku.
- Transformisati kolonu *review* u numerički oblik primenom Vector Space Modela i konkretno, TF-IDF metrike za procenu značajnosti reči. Takođe, proceniti da li bi još neku od varijabli iz polaznog dataset-a trebalo primeniti za kreiranje modela i ako se opredelite da neku / neke varijable uključite, obrazložite ukratko odluku.
- Kreirati prvi klasifikacioni model primenom algoritma Logističke regresije, sa podrazumevanim vrednostima hiperparametara.
- Napraviti predikcije primenom kreiranog modela i izračunati standardne evaluacione metrike (preciznost, odziv, F1) kako za svaku klasu pojedinačno, tako i sveukupno tj na nivou svih klasa. Interpretirati dobijene vrednosti metrika u kontekstu zadatka.
- Kreirati drugi klasifikacioni model kroz postupak podešavanja hiperparametara. U komentaru navesti koje biste hiperparametre podešavali i na koji način tj koristeći koje opsege / liste vrednosti ako ne biste bili vremenski ograničeni. Zatim, izabrati dva hiperparametra, jedan za transformaciju teksta, drugi za klasifikator, odnosno oba za klasifikator ako hiperparametri nisu primenljivi za transformaciju teksta, i izvršite podešavanje njihovih vrednosti kroz postupak (5-fold) kros-validacije.
- Izvršiti predikcije primenom podešenog modela i izračunati standardne evaluacione metrike (preciznost, odziv, F1) kako za svaku klasu pojedinačno, tako i sveukupno tj na nivou svih klasa.
- Uporediti i prokomentarisati rezultate dobijene osnovnim i podešenim modelima.

[1] Podaci su preuzeti sa Kaggle-a, konkretno, sa ovog linka: https://www.kaggle.com/datasets/nelgiriyewithana/mcdonalds-store-reviews i malo sređeni

# Primer zadatka klasterizacije teksta

U fajlu “guardian_news_subset.csv”[2] su dati podaci o novinskim tekstovima koje je objavljivao britanski list Guardian u toku nekoliko godina. Fajl sadrži više kolona (varijabli) od kojih su za ovaj zadatak relevantne samo kolone *webTitle* i *bodyContent*.

Koristeći podatke iz navedenog fajla, potrebno je uraditi sledeće:

- Kreirati novu kolonu *articleText* koja objedinjuje sadržaj kolona *webTitle* i *bodyContent* (kroz obično nadovezivanje stringova).
- Transformisati sadržaj kolone *articleText* u vektorsku (tj numeričku) reprezentaciju primenom pristupa zasnovanom na vektorima reči (word vectors), i konkretno vektorima reči raspoloživim u okviru spaCy medium modela.
- Izvršiti klasterizaciju (transformisanih) novinskih tekstova primenom aglomerativnog hijerarhijskog klasterovanja. Odrediti optimalni broj klastera na osnovu dendrograma i siluet skora (silhouette score). Obrazložiti izbor optimalnog broja klastera.
- Za svaki od klastera odrediti top 10 reči / izraza na osnovu TF-IDF metrike.
- Odrediti veličinu svakog od klastera i opisati svaki klaster na osnovu identifikovanih top 10 reči / izraza, i eventualnog uvida u naslove / sadržaj članaka u okviru klastera.

[2] Podaci su preuzeti sa Kaggle-a, konkretno, sa sledećeg linka: https://www.kaggle.com/datasets/adityakharosekar2/guardian-news-articles i značajno redukovani